

CIN0144 · APRENDIZADO DE MÁQUINA E CIÊNCIA DE DADOS · CIN/UFPE




PREVISÃO DE SUCESSO DE FILMES BRASILEIROS ANTES DA ESTREIA

Um modelo com AUC 0,99 que não aprendeu nada sobre cinema.



Ana Laura Barboza Oliveira dos Santos · Ana Raquel Rodrigues · Laura Virgínia do Nascimento Fonseca

Análise Exploratória de Dados — Entrega 1





É POSSÍVEL PREVER O SUCESSO ANTES DA ESTREIA?

TAREFA

Classificação binária.



Sucesso = público acima da mediana **do ano de lançamento**.

RESTRIÇÃO


Só informação que existia antes da estreia.

O cenário real é um produtor decidindo financiar um projeto que ainda não existe.

BASE

2.626 filmes · 1995–2024
35 atributos

ANCINE · FSA · Leis de incentivo · IPCA/BCB · IBGE — cinco fontes públicas.




O MERCADO MUDOU DE NATUREZA

1995

14 LANÇAMENTOS · MEDIANA 14.230

2024

197 LANÇAMENTOS · MEDIANA 933




14× mais lançamentos, 15× menos público por filme. Não é crise — é composição:
entrou documentário e produção de circuito limitado.

O eixo da direita está em escala logarítmica; em escala linear os últimos quinze anos seriam uma reta colada no zero.

A DEFINIÇÃO DO ALVO DECIDE O PROBLEMA

■ Mediana global — um limiar para 30 anos

■ Mediana do ano — cada filme contra os contemporâneos



86% dos filmes dos anos 1990 contra **26%** dos anos 2020 — mesma definição.

Correlação do ano com o alvo: **-0,364** → **+0,002**.

E as classes ficam em 50,0% / 49,7% por construção — não há desbalanceamento a tratar.

A BILHETERIA É UMA LEI DE POTÊNCIA

2.806


PÚBLICO MEDIANO

148.399

MÉDIA — 53× A MEDIANA

10,0

ASSIMETRIA



1% dos filmes concentra 36% de todo o público. 10% concentram 91%; a metade inferior da base responde por 0,28%.



DUAS DECISÕES DE NÃO FAZER

NÃO REMOVER OUTLIERS

O critério de Tukey marca 17,4% da base — um em cada seis filmes.

Não é base suja: o IQR pressupõe simetria, e a assimetria aqui é 10.

Extremos validados — ingresso mediano R\$ 11,16, nenhum valor negativo.

Num regime de lei de potência, a cauda é o fenômeno.

E uma terceira: não aplicar PCA — são só 11 numéricas úteis; a dimensão cresce na codificação categórica, não nelas.

NÃO BALANCEAR

Classes em 50,0% / 49,7% — por construção do alvo.

O equilíbrio é artefato do corte pela mediana, não propriedade do mundo.

Se a Entrega 2 mudar o limiar, a decisão se inverte.

SMOTE numa base equilibrada seria cumprir tabela.

NEM TODA AUSÊNCIA É A MESMA COISA

61,5%

ESTRUTURAL

não houve coprodução →
categoria própria

23,3%

DE JUNÇÃO

cobertura do IBGE → falha
nossa, não do filme

2,13%


TALVEZ MNAR

max_salas → indicadora, não
imputação

0,84%

SEM ALVO


22 filmes com público “ND”
→ excluir



Fora esses três campos, tudo abaixo de 2% — a base é notavelmente completa para dado administrativo.



CARDINALIDADE E REDUNDÂNCIA



1.738 direções · 467 distribuidoras

287 delas com um único filme na base

agrupar categorias raras

frequência mínima 5–15 · -0,009 de AUC · -380 colunas



$ano \leftrightarrow filmes_no_ano \cdot p = 0,86$

redundância que nós mesmos criamos

escolher um dos dois

manter os dois infla variância no modelo linear

n_ufs · moda em 97,1%

praticamente uma constante


remover

medido: o AUC muda 0,000

Todas as três por **medição**, não por intuição.

O QUE CARREGA INFORMAÇÃO

Escalas diferentes: V de Cramér vai de 0 a 1 e vale para categóricas; ρ de Spearman vai de -1 a 1 e vale para numéricas. Spearman, e não Pearson, por causa da assimetria 10.



ano = +0,002 — o calendário saiu, e por medida. **Gênero (V = 0,338)** é o atributo mais associado da base → codificar categóricas importa mais que transformar numéricas.



VAZAMENTO DE DADOS

Estar na base não é o mesmo que estar disponível antes da estreia. O critério é disponibilidade temporal, não correlação alta.



ANTES DA ESTREIA ✓

gênero · fomento (FSA e leis de incentivo) ·
histórico da direção · histórico da distribuidora ·
UF majoritária · coprodução

Fomento é aprovado antes de a obra existir —
por isso é legítimo.

DEPOIS DA ESTREIA ×

*publico · renda · renda_deflacionada_2024 ·
max_salas*

renda é público × preço: $p = 0,99$ com o alvo — é
a resposta. max_salas é o máximo atingido
durante a carreira, e distribuidora expande filme
que vai bem.



O preço de excluir, medido: honesto 0,832 → + max_salas 0,940 → + renda 0,993. **-0,16 de AUC.**

DE EVIDÊNCIA A DECISÃO

EVIDÊNCIA

DECISÃO DE PRÉ-PROCESSAMENTO

PESO MEDIDO

Alvo global embute o ano	usar <i>sucesso_no_ano</i>	-0,062
<i>renda</i> e <i>max_salas</i> são posteriores à estreia	excluir os dois	-0,163
O uso real é prever o futuro	validação temporal	-0,087
467 distribuidoras, 287 com um filme	agrupar as raras	-0,009
Assimetria 10,0	log só no modelo linear	+0,024 / 0,000
Classes em 50/50 por construção	não balancear	—
A cauda é o fenômeno	não remover outliers	—



UM RESULTADO MAIOR NÃO SIGNIFICA UM MODELO MELHOR

Mesmo algoritmo, mesmo protocolo. Mudam só três decisões.



AUC 0,995

O CAMINHO FÁCIL

alvo global — lê o calendário

renda e max_salas — lê a resposta

k-fold aleatório — vê o futuro

AUC 0,725

COERENTE COM O USO REAL

sucesso_no_ano

só informação pré-estreia

treino até 2017 · teste de 2018 em diante

A diferença, decomposta: alvo $-0,062$ · atributos $-0,163$ · partição $-0,087$. Nenhuma linha de código distingue as duas versões.



É POSSÍVEL PREVER? PARCIALMENTE, SIM.

AUC 0,725

Bem acima do acaso, que seria 0,5. Longe da certeza.
É modesto porque é verdadeiro.

Base, notebook executado e relatório completo em github.com/anaraque-l/bilheteria-cinema-brasileiro

Fontes: ANCINE · FSA · Leis de incentivo · IPCA/BCB · IBGE — todas públicas, sob a Lei 12.527/2011