



Aprendizado de Máquina e Ciência de Dados
Entrega 2 — Pré-processamento e Pipelines

Modelagem Preditiva do Desempenho de Bilheteria do Cinema Brasileiro

Ana Laura Barboza Oliveira dos Santos
Ana Raquel Rodrigues
Laura Virgínia do Nascimento Fonsêca

Recife, 8 de outubro de 2026.

Resumo

Este trabalho avalia sistematicamente o efeito do pré-processamento sobre o desempenho de um classificador k-Nearest Neighbors na previsão de sucesso de bilheteria do cinema brasileiro. Partindo da base de 2.626 filmes analisada na Entrega 1, construímos um pipeline de cinco etapas e avaliamos as 144 combinações possíveis das opções escolhidas, sempre com o mesmo modelo, sete vizinhos, e a mesma partição em cinco folds.

Consideramos sucesso o público acima do percentil 75 dos filmes do ano anterior, limiar conhecido antes da estreia. Restam 2.590 filmes, dos quais 25,3% são sucesso.

As 144 combinações executadas sem falha. Com o modelo fixo, a escolha do pré-processamento move a AUC em 0,122, de 0,731 a 0,853. Três resultados sustentam a discussão. A normalização é a única etapa que decide o desempenho, com 68 vitórias e nenhuma derrota em 108 comparações pareadas. A aplicação de PCA sobre uma matriz não escalada reduz o espaço a dois componentes e custa 0,065 de AUC. E o balanceamento não altera a AUC, mas eleva a revocação em 0,19 em todos os contextos, ao custo de 0,15 de precisão.

Adotamos a regra de empate exigida pelo enunciado, segundo a qual diferença menor que a variabilidade entre folds não sustenta conclusão. Por ela, 104 das outras 143 combinações empatam com a configuração de referência. A validação temporal qualifica esse resultado: a configuração sem nenhuma transformação opcional cai de 0,827 para 0,588 ao prever anos futuros, enquanto as combinações com normalização e encoding pelo alvo permanecem acima de 0,79.

1. Contexto

Queremos prever se um filme brasileiro terá público acima do comum usando apenas informações disponíveis antes da estreia. A base é a listagem oficial da ANCINE de 1995 a 2024, com os dados de fomento público ligados a cada filme. Como a decisão de financiar acontece antes de o filme existir, a pergunta que motiva o trabalho permanece: o dinheiro público está indo para filmes que encontram plateia?

A E1 deixou três atalhos medidos, que inflam o resultado sem ensinar nada ao modelo: a renda como atributo somava 0,161 à AUC, o número máximo de salas somava 0,108 e a divisão aleatória em vez de temporal somava 0,087; somados a um alvo global, levavam a AUC de 0,725 para 0,995. Ela concluiu recomendando o alvo relativo ao ano de lançamento, com validação temporal.

Depois de entregue a E1, auditamos essa recomendação, e é dela que parte esta entrega. A auditoria mostrou duas coisas que a E1 não havia examinado: o público não forma um grupo único, e sim dois, circuito limitado e lançamento comercial, com fronteira perto do percentil 69; e a mediana do próprio ano, que a E1 recomendava, só é conhecida depois que todos os filmes do ano estrearam, o que a torna indisponível para prever antes da estreia.

Nesta entrega o modelo é fixo, um kNN de sete vizinhos, e o que varia são 144 maneiras de preparar os dados para ele. Duas conclusões da E1 entram em revisão por consequência dessa troca de modelo e de alvo. A primeira recomendava não balancear, mas foi medida num alvo meio a meio por construção. A segunda recomendava não aplicar PCA, mas foi medida com floresta aleatória, indiferente a escala e a dimensão. O kNN não é indiferente a nenhuma das duas, e é essa diferença que a grade mede.

2. Base, alvo e atributos

A base permaneceu com os 2.626 longas brasileiros lançados em sala entre 1995 e 2024, montados a partir dos dados abertos da ANCINE, do IBGE e do Banco Central. O módulo que a monta não foi alterado, porque é o entregável congelado da E1.

A definição de sucesso: Público acima do percentil 75 dos filmes do ano anterior. Com ele, 2.590 filmes têm alvo e 36 ficam de fora, 22 sem público informado e 14 de 1995, que não têm ano

anterior. A prevalência de sucesso é de 25,3%, razão de um para três, e se mantém estável entre as décadas 26,7%, 25,2%, 23,0% e 29,1% , porque o limiar acompanha o ano. Essa estabilidade é condição para que a comparação entre pipelines não dependa do período.

Três atributos novos medem a reputação da direção, da distribuidora e da produtora: o logaritmo da mediana do público dos filmes da mesma entidade em anos estritamente anteriores, com ausência quando não há nenhum. Mediana e logaritmo vêm da distribuição do público, lei de potência com Gini de 0,92, em que a média de três filmes de um diretor ficaria próxima do maior deles. Eles carregam o sinal das colunas de identidade que ficaram fora, sem o custo de dimensão que as 1.738 categorias de direção imporiam ao kNN.

Nove numéricas, três de histórico, quatro nominais e duas ordinais. As exclusões aplicam decisões da E1, sendo elas a saída das colunas que só se conhecem depois da estreia, os identificadores, as malformadas, as de alta cardinalidade e as que são função do ano, e uma verificação no código interrompe a execução se qualquer coluna proibida aparecer entre os atributos.

3. As técnicas por etapa

3.1 Valores ausentes

O tratamento é obrigatório: o kNN decide por distância euclidiana, e não há distância definida com valor ausente. A ausência relevante é a dos três históricos, e é estrutural, porque indica que a entidade nunca lançou filme: falta o da direção em 67,88% dos filmes, o da produtora em 59,61% e o da distribuidora em 20,81%. Entre os outros quinze atributos a maior ausência é de 0,46%, e é essa linha que explica por que a etapa só passou a ter conteúdo com a entrada dos históricos.

Opção	O que faz?	Característica dos dados que a motiva
Mediana e Moda	imputa mediana nas numéricas e moda nas categóricas; compõe o baseline	a cauda das contagens de fomento pede mediana, não média; nos históricos, já em logaritmo e com assimetria entre -0,02 e 0,56, as duas coincidem
Indicadora de ausência	imputa mediana e acrescenta sete colunas que marcam o que faltava	a E1 classificou a ausência desta base em quatro naturezas e achou dois casos em que ela carrega informação

A hipótese é que as duas empatem, e a razão está medida: a falta de histórico coincide com a inexistência de filme anterior registrado em mais de 99,8% dos casos. Essa informação já consta de outras colunas, então três das sete indicadores repetem o que a base diz e todas diluem as demais dimensões no cálculo da distância. Imputar por vizinhos foi descartado por não haver o que recuperar numa ausência estrutural.

3.2 Encoding

O encoding é obrigatório porque o kNN não calcula distância sobre texto, e a decisão pesa mais aqui do que pesaria numa árvore: cada coluna criada é uma dimensão a mais na distância euclidiana. O atributo que determina o tamanho do problema é a distribuidora, com 455 categorias, 278 delas com um único filme. As duas ordinais não variam entre combinações: recebem código inteiro na ordem natural das faixas, que preserva a única informação que elas afirmam.

opção	nominais	colunas no kNN	característica dos dados que a motiva
por indicadores	uma coluna por categoria, agrupando as com menos de dez filmes	78, média de 76	a Entrega 1 mediu esse agrupamento: custa 0,009 de AUC e

			remove cerca de 380 colunas
pelo alvo	uma coluna por nominal, com a média do alvo na categoria	18, exatas	455 categorias viram 455 direções em que dois filmes podem diferir; aqui as quatro nominais ocupam quatro dimensões em vez de 64

Com a imputação por indicadora, o encoding pelo alvo sobe para 25 colunas e o de indicadores para até 86, média de 84. O encoding pelo alvo tem duas barreiras independentes contra vazamento: validação cruzada interna, que impede o filme de ser codificado com o próprio rótulo, e o ajuste restrito ao treino de cada fold. Não é técnica vista em sala, e o enunciado aceita técnica adicional mediante justificativa: num classificador que decide por distância, trocar 64 dimensões por quatro é intervenção de natureza diferente das outras etapas. O substituto dentro do programa seria a codificação por frequência.

3.3 Normalização

A distância euclidiana soma as diferenças de todas as colunas sem distinguir o que cada uma mede, e nesta base as escalas são incomparáveis: o ano vai de 1996 a 2024, a contagem de filmes anteriores da distribuidora vai de zero a 179 com mediana 10, os indicadores de fomento valem zero ou um, e os históricos, em logaritmo, ficam entre zero e cerca de sete. Sem correção, as duas colunas de maior amplitude decidem sozinhas quem é vizinho de quem. A etapa age na matriz inteira, depois do encoding, porque é nela que o kNN mede distância.

Opção	O que faz?	Característica dos dados que a motiva
Sem normalização	preserva as escalas cruas; compõe o baseline	testa se as escalas cruas já servem
Padronização	centra em zero e divide pelo desvio-padrão	é o tratamento direto do problema de amplitude acima
Escala por intervalo	comprime cada coluna para zero a um	as binárias do one-hot já vivem nesse intervalo e ficam intactas; o custo é depender do máximo
escala robusta	centra na mediana e divide pelo intervalo interquartil	as contagens de filmes anteriores têm assimetria de 2,0 a 3,8, e mediana e intervalo interquartil são as medidas adequadas a essa cauda

A hipótese não é a de que normalizar ajuda, que seria trivial, mas a de que a melhor normalização depende do encoding. O argumento é aritmético: numa coluna binária em que um por cento dos filmes vale um, o desvio-padrão é cerca de 0,0995, e dividir por ele transforma o valor um em aproximadamente 9,9, de modo que uma categoria rara pesaria dez vezes mais na distância que uma numérica. Daí a previsão de que a padronização renderia menos no espaço dos indicadores e que a escala por intervalo seria a mais segura ali; a seção 5.3 mostra que o efeito medido tem outra forma. Uma transformação de potência antes da escala ficou fora para manter o espaço em 144 combinações.

3.4 Redução de dimensionalidade

Com o encoding por indicadores a matriz chega a cerca de 84 colunas, boa parte quase vazia. Em dimensão alta as distâncias se concentram: o vizinho mais próximo deixa de ser significativamente mais próximo que o mais distante, e o voto dos sete perde o sentido. A Entrega 1 recomendou não aplicar redução de dimensionalidade, com o argumento de que o gargalo da base é categórico e

não numérico; todas as hipóteses dela, porém, foram medidas com floresta aleatória, modelo indiferente a escala e a dimensão.

Opção	Estratégia	Característica dos dados que a motiva
Sem redução	preserva todas as colunas; compõe o baseline	é a recomendação da Entrega 1, agora testada num modelo sensível a dimensão
PCA retendo 95% da variância	troca as colunas por combinações delas	as 84 colunas do one-hot são em boa parte esparsas, e é o caso em que a concentração de distâncias morde
Seleção das dez melhores por informação mútua	mantém colunas originais e descarta o resto	a E1 achou redundância entre atributos, e na distância um atributo ruidoso pesa tanto quanto um útil

A hipótese é que a redução só seja inofensiva na presença da normalização.

3.5 Balanceamento

Com 25,3% de sucessos há um para cada três fracassos. A E1 decidiu não balancear, mas com o alvo na mediana, que divide os filmes ao meio. O kNN prevê sucesso quando pelo menos quatro dos sete vizinhos são sucesso e, como a maioria é fracasso, esse limite raramente é atingido; como o kNN não aceita peso por classe, a única forma de mudar a votação é mudar a proporção no treino.

Opção	O que faz?	Vantagem e Custo
Sem balanceamento	mantém a base	serve de referência, e testa se a decisão da E1 ainda vale
Subamostragem	remove fracassos ao acaso até igualar as classes	equilibra o voto, mas descarta cerca de 1.020 dos 2.070 filmes de cada treino, e o kNN depende de densidade
SMOTE	cria sucessos entre dois sucessos parecidos, usando os cinco mais próximos	não descarta nada, mas no espaço dos indicadores cria filmes impossíveis, com metade de uma distribuidora e metade de outra

A biblioteca de reamostragem garante que o balanceamento aconteça apenas no treino. Duplicar sucessos ao acaso ficou fora porque um filme copiado pode ocupar vários dos sete vizinhos e decidir o voto sozinho, e a versão do SMOTE para categóricas precisa das colunas originais, que aqui já passaram pelo encoding. A hipótese, registrada antes de rodar a grade, é que o balanceamento aumente a revocação e o F1, diminua a precisão e a acurácia, e quase não mexa na AUC, que não depende de ponto de corte.

4. Protocolo executado

Validação. Divisão estratificada em cinco folds, embaralhada, semente 42, gerada uma única vez e gravada com o fold de cada um dos 2.590 filmes; a grade e a robustez leem essa lista e não reconstroem a partição. Todos os folds ficam perto de 25,3% de positivos. A E1 defendeu partição temporal e o enunciado fixa cinco folds: seguimos o enunciado, e a temporal entra na seção 6.

Ajuste apenas no treino. As cinco etapas vivem dentro de um pipeline construído de novo para cada combinação e cada fold, de modo que medianas, categorias e médias dos encodings, parâmetros de escala e eixos do PCA são estimados no treino do fold e aplicados ao teste.

Usamos o pipeline da biblioteca de reamostragem porque só ele aciona o reamostrador apenas no ajuste, deixando o fold de teste intacto.

Ordem das etapas dentro de cada fold: ausentes, encoding, normalização, redução, balanceamento e kNN de sete vizinhos. Ausentes primeiro porque o codificador não aceita valor ausente; normalização depois do encoding porque o kNN mede distância na matriz inteira; redução antes do balanceamento para que os eixos sejam ajustados só com filmes reais; balanceamento por último porque o SMOTE interpola no mesmo espaço em que o kNN vai medir distância. O classificador tem pesos uniformes e distância euclidiana, e é fixado pelo enunciado.

Métricas: O filme de sucesso é a classe positiva. Reportamos as cinco métricas pedidas, acurácia, F1, precisão, revocação e AUC, mais a precisão média, cada uma como média e desvio-padrão amostral dos cinco folds. A acurácia sozinha engana aqui: com 25,3% de sucessos, um modelo que sempre responde fracasso acerta 74,7% das vezes e nunca encontra um sucesso. A AUC é a métrica principal, a mesma da E1, porque mede se o modelo coloca os sucessos acima dos fracassos ao ordenar, sem depender de corte. F1, precisão e revocação medem a decisão final, tomada no corte de quatro votos em sete, e é aí que esperamos o efeito do balanceamento.

Regra de empate: Duas combinações empatam numa métrica quando a diferença entre as médias é menor que o maior dos dois desvios entre folds. A regra atende à exigência do enunciado de que diferença menor que a variabilidade entre folds não sustente conclusão, tem uma única implementação no código e é conservadora, porque gera mais empates do que um teste pareado geraria. A seção 5.2 acrescenta um Wilcoxon pareado como verificação independente.

Reprodutibilidade: Rodar a grade duas vezes no mesmo ambiente produz as mesmas métricas em todos os folds, o que confirma que nenhum transformador ficou sem semente. As versões das bibliotecas estão no anexo, gravadas pela própria execução, e nenhum número deste relatório foi digitado à mão.

O teste de que o histórico não vaza: Os três históricos são o único ponto em que informação de um filme passa por outro, e por isso recebem verificação própria em vez de argumento: o teste multiplica por mil o público de todos os filmes de um ano e confere que nenhum histórico daquele ano ou anterior muda, o que falharia se o histórico olhasse para o próprio ano, e que algum histórico de ano posterior muda, o que garante que o teste toca a coluna. Restra uma limitação, que declaramos: com divisão aleatória, o público de um filme do fold de teste pode compor o histórico de um filme posterior do fold de treino. O rótulo do próprio filme nunca entra nos atributos dele, mas essa contaminação indireta existe e é o que a validação temporal da seção 6 mede.

5. Resultados e discussão

5.1 Visão geral, baseline, melhores e piores

As 144 combinações executaram sem nenhuma falha, de modo que a coluna de erro da tabela do anexo está vazia nas 144 linhas e não há combinação a reportar como inviável.

	Combinação	AUC
Melhor	mediana e moda, encoding pelo alvo, padronização, PCA e subamostragem	0,853 ± 0,016
Baseline	sem nenhuma transformação opcional	0,827 ± 0,014
Pior	indicadora, one-hot, sem normalização, PCA e subamostragem	0,731 ± 0,015

A primeira leitura é a amplitude. Com o modelo fixo em sete vizinhos e os mesmos cinco folds em todas as linhas, a escolha do pré-processamento move a AUC em 0,122. É mais do que qualquer ganho que a Entrega 1 obteve trocando de modelo, e justifica o recorte desta entrega: o pré-processamento não é preparação para o aprendizado, é parte dele.

A segunda leitura vem da regra de empate e é mais incômoda. O baseline ocupa a 61ª posição entre 144, mas **104 das outras 143 combinações** empatam com ele e apenas dez o superam de forma que a variabilidade entre folds sustente; **21 empatam com a melhor, além dela**. O ranking existe, mas boa parte dele é ruído: relatar apenas médias teria anunciado como descoberta uma ordenação que cinco folds não autorizam. O que a grade permite afirmar com segurança não é qual pipeline é o melhor, e sim quais opções nunca prejudicam e quais podem destruir o resultado. A seção 6 acrescenta que a posição nesse ranking também não informa sobre generalização temporal.

Vale notar a composição das pontas. Existem doze combinações que aplicam PCA sem normalização, e elas ocupam exatamente as doze últimas posições, da 133ª à 144ª; em todas chegam 2,0 colunas ao classificador. As melhores têm em comum o encoding pelo alvo e alguma normalização, em qualquer das três. A seção 5.2 separa esses efeitos e a seção 5.3 mostra por que eles não são independentes.

5.2 Efeito isolado de cada etapa

A tabela traz as duas leituras do módulo de análise. A primeira é a que o enunciado pede, a média das combinações agrupadas pela opção, e tem o defeito de misturar contextos. A segunda corrige isso por pareamento: fixa as outras quatro etapas e compara a opção com a de referência dentro de cada contexto, com vitória, empate ou derrota decididos pela regra da seção 4. É a contagem pareada que sustenta afirmação, e é ela que autoriza dizer que uma técnica nunca piorou.

Etapa	Referência	Demais opções: AUC média e pareado em vitórias, empates e derrotas
Ausentes	mediana e moda, 0,820	indicadora 0,818 · 0-68-4 em 72
Encoding	one-hot, 0,815	pelo alvo 0,823 · 13-59-0 em 72
Normalização	sem, 0,790	padronização 0,831 · 22-14-0 · intervalo 0,827 · 23-13-0 · robusta 0,828 · 23-13-0, em 36
Redução	sem, 0,827	PCA 0,809 · 0-36-12 · seleção 0,821 · 0-43-5, em 48
Balanceamento	sem, 0,822	subamostragem 0,821 · 0-44-4 · SMOTE 0,814 · 1-41-6, em 48

A normalização é a única etapa que decide o resultado. As três técnicas somam 68 vitórias, 40 empates e nenhuma derrota em 108 comparações pareadas, com ganho médio entre 0,036 e 0,041. A explicação está na métrica do classificador: a distância euclidiana soma diferenças sem normalizar unidades, e aqui a contagem de filmes anteriores da distribuidora varia de zero a 179 enquanto os indicadores de fomento variam de zero a um. Sem correção, dois filmes são próximos quando têm distribuidoras de porte parecido, e o resto é arredondamento. As três escalas empatam entre si, com diferença máxima de 0,004 contra desvio típico de 0,014 entre folds: o que importa é normalizar, não qual escala escolher.

A redução nunca ganhou. Nem o PCA nem a seleção venceram em um único contexto, e o PCA perdeu em doze. A recomendação da Entrega 1 de não reduzir sobrevive, agora testada com o modelo sensível à dimensão que era a nossa objeção contra ela. Há, porém, um achado de engenharia: a seleção empata com a matriz completa em 43 dos 48 contextos, e nesses casos o kNN decide com dez colunas em vez de cerca de cinquenta.

O encoding pelo alvo tem vantagem pequena e consistente. A diferença média, 0,007, é menor que o desvio entre folds e portanto é empate pela nossa regra; o pareamento mostra 13 vitórias e nenhuma derrota em 72 contextos, padrão difícil de atribuir ao acaso. A leitura honesta é que o efeito existe e é pequeno. O mecanismo é dimensional: dezoito colunas contra cerca de 84, e em dimensão menor as distâncias discriminam melhor.

A indicadora de ausência não acrescentou nada, como a seção 3.1 previa: zero vitórias e quatro derrotas em 72 contextos. A informação já estava na base, porque a falta de histórico coincide com a contagem de filmes anteriores igual a zero em quase todos os casos, e essa contagem é um atributo numérico que o kNN já usa. A indicadora repete em sete colunas novas o que três colunas antigas diziam, e colunas repetidas custam dimensão sem informar.

O balanceamento não move a AUC e muda a decisão, como a seção 4 previu.

Métrica	Sem	Subamostragem	SMOTE	Pareado contra não balancear
Revocação	0,547	0,741	0,736	48 vitórias em 48, para as duas
Precisão	0,692	0,543	0,530	48 derrotas em 48, para as duas
Acurácia	0,825	0,774	0,767	48 derrotas em 48, para as duas
F1	0,609	0,625	0,615	subamostragem: 15 vitórias, 33 empates
AUC	0,822	0,821	0,814	subamostragem: 44 empates, 4 derrotas

Balancear aumenta a revocação em cerca de 0,19 em todos os 48 contextos e cobra 0,15 de precisão e 0,05 de acurácia, também sem exceção. É o que o mecanismo prevê: a AUC avalia a ordenação, que o balanceamento não altera, enquanto revocação e precisão avaliam a decisão tomada no corte de quatro votos em sete. Comparadas diretamente entre si em F1, e não cada uma contra não balancear, a subamostragem vence o SMOTE em doze dos 48 contextos, empata em 34 e perde em dois. A vantagem é pequena mas consistente, e é contraintuitiva, porque a subamostragem descarta metade dos filmes de cada treino; a explicação provável é o espaço em que o SMOTE opera, interpolando numa matriz com colunas de indicadores e produzindo filmes com meia distribuidora, que entram na votação como se fossem reais.

Verificação independente. A regra de empate é o critério do enunciado, e é por ela que o relatório decide. Como checagem, aplicamos também o teste de Wilcoxon pareado sobre as diferenças por fold, aproveitando que os folds são idênticos em todas as combinações. Em 180 pares, as três normalizações superam a ausência de normalização com ganho de 0,041, 0,036 e 0,038 e valores de p entre 10^{-24} e 10^{-28} . Em 240 pares, a subamostragem eleva a revocação em 0,194 e reduz a precisão em 0,150, ambos com p da ordem de 10^{-41} . A única comparação não significativa é justamente a que afirmamos ser nula: o efeito do balanceamento na AUC, com diferença de 0,001 e p de 0,26.

5.3 Interações entre etapas

O enunciado define interação como a técnica que só se mostra benéfica na presença de outra. O módulo de análise procura isso sem intervenção: compara cada opção com a sua referência dentro de cada recorte da outra etapa e marca interação quando o veredito muda de recorte para recorte. Dois pares foram marcados.

A redução depende da normalização.

PCA contra não reduzir, por normalização	vitórias, empates, derrotas	ganho médio	veredito
com padronização	0, 12, 0	+0,000	empate
com escala por intervalo	0, 12, 0	-0,003	empate
com escala robusta	0, 12, 0	-0,003	empate
sem normalização	0, 0, 12	-0,065	perde

O PCA empata com não reduzir nos 36 contextos em que há normalização e perde nos 12 em que não há. A causa não é conjectura: a grade registra quantas colunas chegam ao classificador, e nas combinações de PCA sem normalização esse número é 2,0. O corte de 95% da variância sai em dois componentes, o que faz sentido, porque sem correção de escala a variância total é quase toda da contagem de filmes anteriores da distribuidora e do ano; dois componentes bastam para reproduzir essas duas colunas, e os demais atributos cabem nos 5% descartados. O classificador recebe um espaço de duas dimensões que sabe apenas o porte da distribuidora e o ano. As doze combinações que aplicam PCA sem normalização ocupam exatamente as doze últimas posições do ranking.

O teste pareado acrescenta uma leitura. Sem normalização, a perda de 0,065 tem $p = 2 \cdot 10^{-11}$ em sessenta pares; com normalização, a perda média cai a 0,002 e o teste ainda acusa $p = 0,003$, porque o efeito é minúsculo mas sistemático. É o caso didático da diferença entre as duas leituras: significativo não quer dizer relevante, e 0,002 de AUC está sete vezes abaixo do desvio entre folds. Pela regra do enunciado, que é o critério adotado, isso é empate.

A consequência é uma regra de ordem, não uma preferência de técnica: num pipeline com kNN, a redução por componentes principais precisa vir depois de uma escala, e um pipeline que inverta essa ordem não é subótimo, é um erro de construção. A seleção por informação mútua não apresenta esse comportamento, porque escolhe colunas por associação com o alvo, e associação não depende da unidade em que a coluna está medida.

A normalização rende mais com o encoding pelo alvo. No espaço do encoding pelo alvo, as três escalas vencem a ausência de normalização: a padronização em 15 dos 18 contextos com ganho de 0,047, a escala por intervalo em 17 com ganho de 0,049 e a robusta em 15 com ganho de 0,042. No espaço do one-hot, as três apenas empatam, com ganhos de 0,035, 0,024 e 0,033 e a maioria dos contextos indecisa. É essa mudança de veredito que caracteriza a interação. Nenhuma chega a perder em qualquer recorte, de modo que a recomendação de normalizar não muda; o que muda é quanto se ganha.

O resultado tem forma diferente da prevista na seção 3.3. Esperávamos que a padronização sofresse no one-hot pelo fator 9,9 das binárias raras, e que a escala por intervalo fosse a mais segura ali. O medido mostra o contrário: a escala por intervalo é a que mais perde ao sair do encoding pelo alvo para o one-hot, de 0,049 para 0,024, enquanto a padronização cai menos, de 0,047 para 0,035.

A explicação inverte o nosso próprio argumento. A escala por intervalo não mexe nas colunas binárias, mas comprime as numéricas de cauda longa para uma faixa estreita perto de zero, já que são governadas pelo máximo; as cerca de 84 colunas de indicadores passam a ter amplitude efetiva maior que as numéricas e dominam a distância. A padronização iguala a dispersão de todas as colunas, inclusive as binárias, e impede que qualquer grupo domine. Quanto ao fator 9,9, a explicação provável para a sua ausência está numa decisão da etapa anterior: o one-hot agrupa as categorias com menos de dez filmes, de modo que as colunas raríssimas das quais o argumento dependia não chegam a existir. É hipótese compatível com o medido, não efeito isolado; isolá-lo exigiria rodar a grade sem esse agrupamento, o que fica como extensão na seção 7.

O par balanceamento e normalização não muda de veredito, com empate agregado em todos os recortes, ainda que haja derrotas isoladas do SMOTE. A magnitude, porém, troca de sinal: a subamostragem tem ganho médio de -0,013 sem normalização e de +0,007 com padronização, porque ela descarta metade dos filmes e a perda de densidade agrava um espaço já decidido por duas colunas.

5.4 Custo

A grade inteira levou 3,9 minutos de ajuste e predição somados, com mediana de 0,92 segundo por combinação e máximo de 3,99 segundos.

O custo se concentra em duas escolhas. A seleção por informação mútua custa 2,60 segundos em média, contra 0,76 de não reduzir e 1,49 do PCA; e o encoding por indicadores custa 2,21 contra 1,02 do encoding pelo alvo. As dez combinações mais caras da grade são todas interseção das duas, e todas usam a imputação por indicadora. As outras três etapas não

diferenciam custo: entre a opção mais barata e a mais cara de ausentes, normalização ou balanceamento há no máximo 0,42 segundo. Vale registrar que a normalização, que domina o resultado, é praticamente de graça, e que as três escalas custam o mesmo entre si, com diferença de 0,07 segundo.

A leitura interessante é outra: **o número de colunas que chega ao classificador não prediz o tempo**. A correlação de Spearman entre as duas grandezas é de $-0,144$, com p de 0,086, ou seja, nem sequer é distinguível de zero, e o sinal negativo que ela sugere é o oposto do que a intuição esperaria. O motivo aparece nas dez combinações mais caras: todas entregam exatamente dez colunas ao kNN, porque todas usam a seleção. Nelas, o ajuste consome 75% do tempo, contra 22% nas combinações sem redução, porque estimar informação mútua entre 84 colunas e o alvo, cinco vezes, custa mais do que o classificador medir distância depois. Na grade inteira ajuste e predição se dividem quase ao meio, 51% contra 49%: o deslocamento para o ajuste é efeito da seleção, não uma característica geral do experimento.

6. Robustez: temporal, troca de limiar e por gênero

A seção 5 mede tudo sob um único arranjo. Esta seção pergunta o que sobrevive quando ele muda. Doze combinações passaram pelas três checagens: o baseline, as cinco melhores, as cinco piores e a melhor de cada opção de balanceamento.

Validação temporal, com treino até 2017 e teste de 2018 em diante, que é a validação defendida pela E1 e substituída pelo enunciado desta entrega.

Grupo, com os doze identificadores	AUC em cinco folds	AUC temporal	Otimismo
Baseline, sem transformação opcional (1)	0,827	0,588	0,239
As cinco melhores da grade (50, 58, 47, 55, 122)	0,847 a 0,853	0,738 a 0,799	0,049 a 0,113
A melhor com SMOTE (60)	0,842	0,739	0,104
As cinco com PCA sem normalização (76, 41, 113, 5, 77)	0,731 a 0,750	0,531 a 0,556	0,176 a 0,219

Todas as doze são otimistas na divisão aleatória, o que a seção 4 já declarava. O que não esperávamos é a distribuição desse otimismo: o baseline é o mais otimista de todos e cai para 0,588, quase o acaso, enquanto as três melhores perdem entre 0,049 e 0,060 e seguem acima de 0,79. O pré-processamento, portanto, não melhora apenas o número do relatório: muda o que o modelo aprende. Sem escala, a distância é decidida pelo ano e pela contagem de filmes anteriores da distribuidora, como mostra a seção 5.3, e as duas crescem com o tempo: todo filme do teste é de um ano que o treino não tem, e as distribuidoras chegam ao teste com mais filmes acumulados. Por isso, as combinações de PCA sem normalização, que guardam só essas duas colunas, têm otimismo próximo ao do baseline.

Troca do corte do alvo. Nos percentis 50, 75 e 90, a correlação de Spearman entre as ordenações é de 0,825 entre P50 e P75, de 0,867 entre P75 e P90 e de 0,664 entre P50 e P90, todas significativas: a ordenação é estável, e menos nos extremos, o que é natural porque P50 e P90 definem problemas diferentes. A separação qualitativa não muda em nenhum dos três cortes.

Desempenho por gênero, que revela a limitação mais séria do modelo. Em ficção, 1.627 filmes com prevalência de 35,6%, a AUC da melhor combinação é 0,832 e a revocação, 0,826. Em documentário, 908 filmes com prevalência de 5,6%, a AUC cai para 0,693 e a revocação para 0,118: mesmo o melhor pipeline encontra menos de um em cada oito documentários de sucesso. A queda de 0,13 na AUC indica que os atributos descrevem mal o que faz um documentário encontrar plateia, e a revocação é o mecanismo do balanceamento no extremo, porque com 5,6% de prevalência menos de um dos sete vizinhos é sucesso e o corte de quatro votos fica

inalcançável. Balancear o conjunto inteiro não resolve, porque equaliza a proporção global e não a da vizinhança em que o documentário vive.

7. Lições, limitações e conclusão

Uma etapa decide, e as outras quatro são empate. Normalizar move a AUC em cerca de 0,04 e nunca prejudicou em 108 comparações pareadas; as demais etapas empatam na maioria dos contextos. Para um classificador que decide por distância isso é coerente, porque a única etapa que altera diretamente a métrica de distância é a que mexe na escala.

O perigo não está nas técnicas ruins, está nas combinações incoerentes. A pior configuração da grade não usa nenhuma técnica desaconselhada: aplica PCA, que é padrão, sobre uma matriz não escalada, e sobram dois componentes; **nas doze vezes em que isso ocorre, o PCA perde em média 0,065 de AUC.** A lição vale para qualquer pipeline em que uma etapa pressuponha o trabalho de outra, e é o argumento mais forte a favor de examinar o espaço de combinações em vez de ajustar uma etapa por vez.

Reduzir não melhora, mas pode baratear. Nenhuma opção de redução venceu em um único contexto, e ainda assim a seleção empatou com a matriz completa em 43 dos 48, o que significa que quatro quintos das colunas podem ser descartados sem custo mensurável em AUC.

A regra de empate mudou o relatório, e a validação temporal mostrou o limite dela. Com 104 das 143 combinações empatando com o baseline, quase nada do que um ranking por média sugeriria sobrevive à variabilidade entre cinco folds. A seção 6 acrescenta outro recado: o baseline, que empatou com quase todo mundo em cinco folds, é o que mais perde ao prever o futuro, caindo de 0,827 para 0,588, enquanto as melhores perdem cerca de 0,05. Posição em ranking de cinco folds não informa sobre generalização temporal, e nenhum protocolo único basta para decidir. A leitura que fica é que o pré-processamento não melhora o modelo, muda o que ele aprende: corrigir a escala produz um modelo que perde cerca de 0,05 ao prever o futuro, em vez de 0,24, porque deixa de escolher vizinhos pelo ano e pelas contagens acumuladas.

Limitações e extensões. A contaminação indireta entre folds decorre de o enunciado fixar divisão aleatória; a revocação de 0,118 em documentário mostra que o modelo não serve para esse segmento, e nenhuma combinação com boa AUC corrige isso; e o número de vizinhos, fixado em sete, interage com o balanceamento de forma que não pudemos explorar. Daí as três extensões: transformação de potência antes da escala, rodar a grade sem o agrupamento de categorias raras, e ajustar o número de vizinhos com limiar próprio por gênero.

Referências

AGÊNCIA NACIONAL DO CINEMA. **Listagem de filmes brasileiros lançados em salas de exibição, 1995–2024**. Rio de Janeiro: ANCINE, 2025. Dado aberto federal.

AGÊNCIA NACIONAL DO CINEMA. **Obras com investimento do Fundo Setorial do Audiovisual**. Rio de Janeiro: ANCINE, 2025. Licença Creative Commons.

AGÊNCIA NACIONAL DO CINEMA. **Obras com fomento indireto aprovado**. Rio de Janeiro: ANCINE, 2025. Licença Creative Commons.

BANCO CENTRAL DO BRASIL. **Série 433 — índice nacional de preços ao consumidor amplo**. Brasília: BCB, 2025.

CHAWLA, N. V. et al. SMOTE: synthetic minority over-sampling technique. **Journal of Artificial Intelligence Research**, v. 16, p. 321–357, 2002.

GRUPO 11. **Entrega 1 — análise exploratória de dados: modelagem preditiva do desempenho de bilheteria do cinema brasileiro**. Recife: CIn/UFPE, 2026.

INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA. **Estimativas da população residente**. Rio de Janeiro: IBGE, 2025.

KRASKOV, A.; STÖGBAUER, H.; GRASSBERGER, P. Estimating mutual information. **Physical Review E**, v. 69, n. 6, 066138, 2004.

LEMAÎTRE, G.; NOGUEIRA, F.; ARIDAS, C. K. Imbalanced-learn: a Python toolbox to tackle the curse of imbalanced datasets in machine learning. **Journal of Machine Learning Research**, v. 18, n. 17, p. 1–5, 2017.

MICCI-BARRECA, D. A preprocessing scheme for high-cardinality categorical attributes in classification and prediction problems. **ACM SIGKDD Explorations Newsletter**, v. 3, n. 1, p. 27–32, 2001.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011.

Anexo

A. Tabela completa das 144 combinações

Uma linha por combinação, com o identificador, a opção adotada em cada uma das cinco etapas, média e desvio-padrão das seis métricas, o número de colunas que chegaram ao classificador, o tempo de execução e a coluna de erro. A coluna de erro está vazia nas 144 linhas: nenhuma combinação falhou. Gerada por python src/e2/anexo.py a partir de reports/e2/resultados.csv, e disponível também em valores separados por vírgula no mesmo diretório. O identificador marcado com "base" é a configuração de referência.

id	ausentes	encoding	normalizacao	reducao	balanceamento	acurácia	F1	precisão	revocação	AUC	AP	atributos	tempo (s)	erro
1 (base)	mediana	one-hot	sem	sem	sem	0,807 ± 0,013	0,543 ± 0,035	0,673 ± 0,036	0,456 ± 0,036	0,827 ± 0,014	0,585 ± 0,023	76	0,9	
2	mediana	one-hot	sem	sem	subam.	0,741 ± 0,030	0,588 ± 0,039	0,492 ± 0,038	0,731 ± 0,041	0,807 ± 0,029	0,536 ± 0,025	76	0,8	
3	mediana	one-hot	sem	sem	SMOTE	0,756 ± 0,013	0,612 ± 0,016	0,512 ± 0,016	0,763 ± 0,020	0,819 ± 0,013	0,568 ± 0,030	76	0,9	
4	mediana	one-hot	sem	PCA	sem	0,779 ± 0,011	0,464 ± 0,013	0,600 ± 0,044	0,379 ± 0,010	0,751 ± 0,012	0,502 ± 0,023	2	0,7	
5	mediana	one-hot	sem	PCA	subam.	0,671 ± 0,016	0,516 ± 0,010	0,411 ± 0,014	0,694 ± 0,025	0,732 ± 0,015	0,459 ± 0,022	2	0,7	
6	mediana	one-hot	sem	PCA	SMOTE	0,735 ± 0,016	0,538 ± 0,030	0,481 ± 0,025	0,610 ± 0,038	0,762 ± 0,017	0,520 ± 0,026	2	0,7	
7	mediana	one-hot	sem	seleção	sem	0,820 ± 0,007	0,597 ± 0,020	0,687 ± 0,016	0,527 ± 0,026	0,813 ± 0,007	0,606 ± 0,008	10	3,4	
8	mediana	one-hot	sem	seleção	subam.	0,766 ± 0,028	0,619 ± 0,033	0,527 ± 0,042	0,751 ± 0,031	0,812 ± 0,016	0,587 ± 0,020	10	3,3	
9	mediana	one-hot	sem	seleção	SMOTE	0,770 ± 0,012	0,612 ± 0,016	0,533 ± 0,018	0,717 ± 0,012	0,809 ± 0,010	0,573 ± 0,024	10	3,4	
10	mediana	one-hot	padrão	sem	sem	0,833 ± 0,009	0,639 ± 0,020	0,703 ± 0,024	0,587 ± 0,027	0,833 ± 0,020	0,632 ± 0,007	76	0,7	
11	mediana	one-hot	padrão	sem	subam.	0,796 ± 0,005	0,650 ± 0,017	0,574 ± 0,006	0,751 ± 0,039	0,836 ± 0,016	0,629 ± 0,010	76	0,7	
12	mediana	one-hot	padrão	sem	SMOTE	0,779 ± 0,009	0,635 ± 0,010	0,545 ± 0,013	0,761 ± 0,022	0,827 ± 0,018	0,600 ± 0,022	76	0,8	
13	mediana	one-hot	padrão	PCA	sem	0,837 ± 0,008	0,650 ± 0,026	0,712 ± 0,012	0,598 ± 0,040	0,830 ± 0,019	0,636 ± 0,015	59	2,1	
14	mediana	one-hot	padrão	PCA	subam.	0,790 ± 0,004	0,647 ± 0,013	0,563 ± 0,007	0,763 ± 0,035	0,835 ± 0,016	0,632 ± 0,015	59	2,4	
15	mediana	one-hot	padrão	PCA	SMOTE	0,778 ± 0,012	0,636 ± 0,018	0,542 ± 0,016	0,771 ± 0,029	0,825 ± 0,018	0,602 ± 0,023	59	3,0	
16	mediana	one-hot	padrão	seleção	sem	0,821 ± 0,012	0,609 ± 0,016	0,683 ± 0,042	0,550 ± 0,016	0,820 ± 0,016	0,623 ± 0,029	10	3,6	
17	mediana	one-hot	padrão	seleção	subam.	0,796 ± 0,025	0,652 ± 0,028	0,575 ± 0,040	0,754 ± 0,016	0,828 ± 0,017	0,619 ± 0,028	10	3,6	
18	mediana	one-hot	padrão	seleção	SMOTE	0,780 ± 0,017	0,619 ± 0,020	0,551 ± 0,028	0,706 ± 0,021	0,807 ± 0,016	0,575 ± 0,020	10	3,5	
19	mediana	one-hot	intervalo	sem	sem	0,832 ± 0,011	0,640 ± 0,029	0,699 ± 0,020	0,590 ± 0,039	0,832 ± 0,015	0,638 ± 0,016	76	0,7	
20	mediana	one-hot	intervalo	sem	subam.	0,766 ± 0,010	0,622 ± 0,014	0,526 ± 0,014	0,763 ± 0,028	0,826 ± 0,014	0,604 ± 0,023	76	0,7	
21	mediana	one-hot	intervalo	sem	SMOTE	0,721 ± 0,017	0,586 ± 0,015	0,470 ± 0,020	0,780 ± 0,025	0,805 ± 0,003	0,559 ± 0,019	76	0,9	

id	ausentes	encoding	normalizacao	reducao	balanceamento	acurácia	F1	precisão	revocação	AUC	AP	atributos	tempo (s)	erro
22	mediana	one-hot	intervalo	PCA	sem	0,830 ± 0,011	0,614 ± 0,031	0,720 ± 0,029	0,535 ± 0,036	0,824 ± 0,016	0,629 ± 0,024	41	2,5	
23	mediana	one-hot	intervalo	PCA	subam.	0,756 ± 0,013	0,607 ± 0,015	0,513 ± 0,018	0,745 ± 0,025	0,815 ± 0,014	0,585 ± 0,020	41	3,1	
24	mediana	one-hot	intervalo	PCA	SMOTE	0,751 ± 0,013	0,601 ± 0,020	0,506 ± 0,018	0,742 ± 0,043	0,810 ± 0,008	0,572 ± 0,020	41	3,0	
25	mediana	one-hot	intervalo	seleção	sem	0,824 ± 0,009	0,613 ± 0,013	0,693 ± 0,035	0,550 ± 0,018	0,820 ± 0,015	0,619 ± 0,017	10	3,5	
26	mediana	one-hot	intervalo	seleção	subam.	0,793 ± 0,024	0,642 ± 0,028	0,574 ± 0,042	0,729 ± 0,011	0,825 ± 0,017	0,617 ± 0,026	10	3,4	
27	mediana	one-hot	intervalo	seleção	SMOTE	0,780 ± 0,017	0,622 ± 0,023	0,550 ± 0,028	0,716 ± 0,026	0,809 ± 0,016	0,575 ± 0,015	10	3,6	
28	mediana	one-hot	robusta	sem	sem	0,829 ± 0,011	0,622 ± 0,019	0,704 ± 0,044	0,560 ± 0,031	0,835 ± 0,014	0,632 ± 0,027	76	0,8	
29	mediana	one-hot	robusta	sem	subam.	0,781 ± 0,019	0,641 ± 0,023	0,547 ± 0,030	0,775 ± 0,020	0,837 ± 0,020	0,610 ± 0,034	76	0,8	
30	mediana	one-hot	robusta	sem	SMOTE	0,752 ± 0,014	0,613 ± 0,014	0,506 ± 0,017	0,777 ± 0,023	0,814 ± 0,013	0,569 ± 0,036	76	0,9	
31	mediana	one-hot	robusta	PCA	sem	0,819 ± 0,010	0,601 ± 0,034	0,677 ± 0,022	0,543 ± 0,053	0,826 ± 0,011	0,624 ± 0,014	20	2,1	
32	mediana	one-hot	robusta	PCA	subam.	0,778 ± 0,016	0,636 ± 0,021	0,543 ± 0,024	0,768 ± 0,027	0,832 ± 0,018	0,602 ± 0,023	20	2,4	
33	mediana	one-hot	robusta	PCA	SMOTE	0,764 ± 0,014	0,624 ± 0,014	0,523 ± 0,021	0,774 ± 0,014	0,818 ± 0,009	0,573 ± 0,014	20	2,4	
34	mediana	one-hot	robusta	seleção	sem	0,822 ± 0,013	0,615 ± 0,027	0,679 ± 0,035	0,563 ± 0,036	0,824 ± 0,016	0,625 ± 0,019	10	3,5	
35	mediana	one-hot	robusta	seleção	subam.	0,787 ± 0,026	0,636 ± 0,032	0,563 ± 0,043	0,732 ± 0,031	0,823 ± 0,020	0,600 ± 0,027	10	3,6	
36	mediana	one-hot	robusta	seleção	SMOTE	0,778 ± 0,018	0,623 ± 0,023	0,546 ± 0,028	0,726 ± 0,030	0,811 ± 0,019	0,580 ± 0,027	10	3,6	
37	mediana	alvo	sem	sem	sem	0,807 ± 0,012	0,532 ± 0,033	0,685 ± 0,044	0,436 ± 0,037	0,821 ± 0,017	0,578 ± 0,029	18	0,8	
38	mediana	alvo	sem	sem	subam.	0,745 ± 0,028	0,584 ± 0,035	0,497 ± 0,037	0,708 ± 0,034	0,800 ± 0,027	0,528 ± 0,030	18	0,6	
39	mediana	alvo	sem	sem	SMOTE	0,763 ± 0,013	0,609 ± 0,027	0,522 ± 0,017	0,731 ± 0,051	0,817 ± 0,016	0,569 ± 0,033	18	0,8	
40	mediana	alvo	sem	PCA	sem	0,781 ± 0,015	0,470 ± 0,023	0,609 ± 0,054	0,384 ± 0,012	0,752 ± 0,014	0,510 ± 0,025	2	0,6	
41	mediana	alvo	sem	PCA	subam.	0,670 ± 0,013	0,515 ± 0,012	0,410 ± 0,013	0,693 ± 0,023	0,733 ± 0,015	0,461 ± 0,024	2	0,7	
42	mediana	alvo	sem	PCA	SMOTE	0,738 ± 0,014	0,547 ± 0,028	0,486 ± 0,023	0,625 ± 0,038	0,763 ± 0,013	0,525 ± 0,023	2	0,6	
43	mediana	alvo	sem	seleção	sem	0,816 ± 0,006	0,580 ± 0,020	0,686 ± 0,018	0,503 ± 0,030	0,803 ± 0,012	0,584 ± 0,013	10	1,3	
44	mediana	alvo	sem	seleção	subam.	0,770 ± 0,024	0,609 ± 0,033	0,535 ± 0,039	0,708 ± 0,032	0,805 ± 0,018	0,587 ± 0,019	10	1,3	
45	mediana	alvo	sem	seleção	SMOTE	0,768 ± 0,017	0,604 ± 0,014	0,532 ± 0,030	0,702 ± 0,042	0,797 ± 0,016	0,555 ± 0,018	10	1,3	
46	mediana	alvo	padrão	sem	sem	0,841 ± 0,012	0,659 ± 0,025	0,721 ± 0,042	0,609 ± 0,041	0,835 ± 0,009	0,648 ± 0,017	18	0,7	
47	mediana	alvo	padrão	sem	subam.	0,796 ± 0,018	0,650 ± 0,027	0,575 ± 0,028	0,748 ± 0,035	0,848 ± 0,017	0,649 ± 0,026	18	0,7	

id	ausentes	encoding	normalizacao	reducao	balanceamento	acurácia	F1	precisão	revocação	AUC	AP	atributos	tempo (s)	erro
48	mediana	alvo	padrão	sem	SMOTE	0,778 ± 0,008	0,632 ± 0,008	0,544 ± 0,013	0,755 ± 0,027	0,824 ± 0,008	0,596 ± 0,017	18	0,7	
49	mediana	alvo	padrão	PCA	sem	0,841 ± 0,010	0,661 ± 0,023	0,718 ± 0,037	0,615 ± 0,040	0,841 ± 0,015	0,651 ± 0,016	12	0,8	
50	mediana	alvo	padrão	PCA	subam.	0,794 ± 0,015	0,652 ± 0,021	0,570 ± 0,024	0,763 ± 0,029	0,853 ± 0,016	0,652 ± 0,025	12	0,8	
51	mediana	alvo	padrão	PCA	SMOTE	0,776 ± 0,016	0,628 ± 0,016	0,542 ± 0,026	0,749 ± 0,035	0,831 ± 0,008	0,605 ± 0,019	12	1,0	
52	mediana	alvo	padrão	seleção	sem	0,843 ± 0,010	0,668 ± 0,019	0,719 ± 0,028	0,624 ± 0,023	0,829 ± 0,010	0,648 ± 0,022	10	1,5	
53	mediana	alvo	padrão	seleção	subam.	0,804 ± 0,015	0,657 ± 0,016	0,590 ± 0,030	0,743 ± 0,016	0,836 ± 0,008	0,638 ± 0,024	10	1,3	
54	mediana	alvo	padrão	seleção	SMOTE	0,778 ± 0,016	0,626 ± 0,012	0,547 ± 0,030	0,735 ± 0,020	0,816 ± 0,018	0,597 ± 0,035	10	1,6	
55	mediana	alvo	intervalo	sem	sem	0,839 ± 0,011	0,645 ± 0,029	0,725 ± 0,027	0,581 ± 0,035	0,848 ± 0,014	0,649 ± 0,026	18	0,7	
56	mediana	alvo	intervalo	sem	subam.	0,797 ± 0,009	0,648 ± 0,011	0,577 ± 0,016	0,739 ± 0,011	0,846 ± 0,013	0,641 ± 0,022	18	0,6	
57	mediana	alvo	intervalo	sem	SMOTE	0,785 ± 0,012	0,642 ± 0,011	0,555 ± 0,019	0,761 ± 0,014	0,839 ± 0,013	0,612 ± 0,033	18	0,7	
58	mediana	alvo	intervalo	PCA	sem	0,839 ± 0,009	0,654 ± 0,022	0,716 ± 0,024	0,602 ± 0,030	0,850 ± 0,010	0,642 ± 0,021	9	0,7	
59	mediana	alvo	intervalo	PCA	subam.	0,791 ± 0,010	0,646 ± 0,015	0,564 ± 0,015	0,755 ± 0,028	0,843 ± 0,017	0,627 ± 0,018	9	0,7	
60	mediana	alvo	intervalo	PCA	SMOTE	0,788 ± 0,011	0,642 ± 0,009	0,561 ± 0,020	0,752 ± 0,015	0,842 ± 0,011	0,624 ± 0,026	9	0,7	
61	mediana	alvo	intervalo	seleção	sem	0,845 ± 0,008	0,664 ± 0,013	0,737 ± 0,034	0,606 ± 0,025	0,834 ± 0,004	0,652 ± 0,018	10	1,4	
62	mediana	alvo	intervalo	seleção	subam.	0,806 ± 0,014	0,655 ± 0,018	0,596 ± 0,029	0,726 ± 0,019	0,838 ± 0,009	0,644 ± 0,014	10	1,3	
63	mediana	alvo	intervalo	seleção	SMOTE	0,793 ± 0,019	0,647 ± 0,020	0,570 ± 0,035	0,749 ± 0,015	0,829 ± 0,011	0,613 ± 0,030	10	1,4	
64	mediana	alvo	robusta	sem	sem	0,830 ± 0,005	0,632 ± 0,014	0,697 ± 0,026	0,580 ± 0,033	0,836 ± 0,013	0,636 ± 0,018	18	0,7	
65	mediana	alvo	robusta	sem	subam.	0,802 ± 0,009	0,657 ± 0,012	0,583 ± 0,017	0,751 ± 0,011	0,842 ± 0,012	0,626 ± 0,020	18	0,6	
66	mediana	alvo	robusta	sem	SMOTE	0,771 ± 0,010	0,627 ± 0,008	0,533 ± 0,016	0,763 ± 0,022	0,823 ± 0,010	0,590 ± 0,026	18	0,8	
67	mediana	alvo	robusta	PCA	sem	0,834 ± 0,009	0,642 ± 0,027	0,707 ± 0,025	0,590 ± 0,049	0,835 ± 0,011	0,636 ± 0,023	10	0,8	
68	mediana	alvo	robusta	PCA	subam.	0,793 ± 0,016	0,643 ± 0,017	0,570 ± 0,031	0,739 ± 0,022	0,835 ± 0,018	0,616 ± 0,024	10	0,8	
69	mediana	alvo	robusta	PCA	SMOTE	0,785 ± 0,013	0,641 ± 0,020	0,555 ± 0,019	0,758 ± 0,036	0,824 ± 0,007	0,593 ± 0,016	10	0,8	
70	mediana	alvo	robusta	seleção	sem	0,835 ± 0,010	0,650 ± 0,023	0,700 ± 0,026	0,607 ± 0,033	0,830 ± 0,012	0,632 ± 0,032	10	1,4	
71	mediana	alvo	robusta	seleção	subam.	0,791 ± 0,020	0,643 ± 0,023	0,566 ± 0,035	0,746 ± 0,019	0,834 ± 0,010	0,620 ± 0,030	10	1,4	
72	mediana	alvo	robusta	seleção	SMOTE	0,770 ± 0,032	0,623 ± 0,034	0,535 ± 0,047	0,746 ± 0,011	0,818 ± 0,017	0,588 ± 0,035	10	1,6	
73	indicador a	one-hot	sem	sem	sem	0,806 ± 0,013	0,539 ± 0,039	0,672 ± 0,035	0,451 ± 0,043	0,826 ± 0,013	0,583 ± 0,022	84	0,8	

id	ausente s	encodin g	normaliz acao	reducao	balance amento	acurácia	F1	precisão	revocaç ão	AUC	AP	atributo s	tempo (s)	erro
74	indicador a	one-hot	sem	sem	subam.	0,738 ± 0,025	0,583 ± 0,031	0,488 ± 0,031	0,725 ± 0,033	0,804 ± 0,027	0,537 ± 0,021	84	0,8	
75	indicador a	one-hot	sem	sem	SMOTE	0,749 ± 0,012	0,605 ± 0,014	0,503 ± 0,016	0,758 ± 0,024	0,818 ± 0,011	0,568 ± 0,025	84	0,9	
76	indicador a	one-hot	sem	PCA	sem	0,781 ± 0,012	0,465 ± 0,011	0,613 ± 0,050	0,376 ± 0,009	0,750 ± 0,016	0,503 ± 0,023	2	0,8	
77	indicador a	one-hot	sem	PCA	subam.	0,670 ± 0,017	0,515 ± 0,011	0,410 ± 0,014	0,694 ± 0,025	0,731 ± 0,015	0,459 ± 0,024	2	0,8	
78	indicador a	one-hot	sem	PCA	SMOTE	0,736 ± 0,018	0,539 ± 0,032	0,482 ± 0,028	0,612 ± 0,040	0,762 ± 0,017	0,524 ± 0,027	2	0,8	
79	indicador a	one-hot	sem	seleção	sem	0,827 ± 0,015	0,612 ± 0,037	0,706 ± 0,036	0,541 ± 0,046	0,814 ± 0,013	0,610 ± 0,024	10	3,7	
80	indicador a	one-hot	sem	seleção	subam.	0,772 ± 0,027	0,624 ± 0,031	0,537 ± 0,041	0,746 ± 0,030	0,813 ± 0,018	0,591 ± 0,021	10	3,6	
81	indicador a	one-hot	sem	seleção	SMOTE	0,776 ± 0,023	0,615 ± 0,025	0,545 ± 0,036	0,706 ± 0,010	0,812 ± 0,013	0,581 ± 0,008	10	3,8	
82	indicador a	one-hot	padrão	sem	sem	0,833 ± 0,008	0,642 ± 0,015	0,701 ± 0,027	0,593 ± 0,023	0,833 ± 0,019	0,633 ± 0,007	84	0,8	
83	indicador a	one-hot	padrão	sem	subam.	0,795 ± 0,006	0,648 ± 0,016	0,571 ± 0,007	0,751 ± 0,036	0,837 ± 0,013	0,628 ± 0,011	84	0,7	
84	indicador a	one-hot	padrão	sem	SMOTE	0,769 ± 0,024	0,626 ± 0,024	0,531 ± 0,033	0,763 ± 0,025	0,825 ± 0,016	0,597 ± 0,019	84	0,8	
85	indicador a	one-hot	padrão	PCA	sem	0,832 ± 0,005	0,642 ± 0,016	0,696 ± 0,022	0,598 ± 0,035	0,827 ± 0,022	0,626 ± 0,007	61	2,9	
86	indicador a	one-hot	padrão	PCA	subam.	0,785 ± 0,012	0,640 ± 0,019	0,555 ± 0,017	0,757 ± 0,031	0,833 ± 0,015	0,623 ± 0,015	61	2,2	
87	indicador a	one-hot	padrão	PCA	SMOTE	0,766 ± 0,021	0,617 ± 0,025	0,528 ± 0,029	0,745 ± 0,035	0,820 ± 0,020	0,597 ± 0,026	61	3,3	
88	indicador a	one-hot	padrão	seleção	sem	0,827 ± 0,007	0,627 ± 0,015	0,692 ± 0,032	0,575 ± 0,032	0,824 ± 0,010	0,625 ± 0,022	10	3,9	
89	indicador a	one-hot	padrão	seleção	subam.	0,799 ± 0,016	0,651 ± 0,022	0,580 ± 0,026	0,743 ± 0,034	0,828 ± 0,018	0,620 ± 0,033	10	3,9	
90	indicador a	one-hot	padrão	seleção	SMOTE	0,779 ± 0,014	0,622 ± 0,013	0,548 ± 0,024	0,719 ± 0,023	0,812 ± 0,009	0,574 ± 0,024	10	3,9	
91	indicador a	one-hot	intervalo	sem	sem	0,825 ± 0,004	0,624 ± 0,012	0,681 ± 0,010	0,576 ± 0,022	0,823 ± 0,024	0,617 ± 0,026	84	0,7	
92	indicador a	one-hot	intervalo	sem	subam.	0,754 ± 0,018	0,611 ± 0,029	0,509 ± 0,023	0,765 ± 0,039	0,818 ± 0,018	0,584 ± 0,028	84	0,7	
93	indicador a	one-hot	intervalo	sem	SMOTE	0,724 ± 0,017	0,587 ± 0,026	0,471 ± 0,020	0,778 ± 0,046	0,804 ± 0,021	0,561 ± 0,025	84	0,8	
94	indicador a	one-hot	intervalo	PCA	sem	0,819 ± 0,015	0,591 ± 0,030	0,687 ± 0,043	0,518 ± 0,028	0,809 ± 0,020	0,596 ± 0,032	41	2,7	
95	indicador a	one-hot	intervalo	PCA	subam.	0,747 ± 0,017	0,603 ± 0,023	0,500 ± 0,021	0,762 ± 0,032	0,812 ± 0,020	0,571 ± 0,021	41	2,2	
96	indicador a	one-hot	intervalo	PCA	SMOTE	0,737 ± 0,019	0,591 ± 0,033	0,486 ± 0,023	0,752 ± 0,054	0,799 ± 0,021	0,562 ± 0,024	41	2,6	
97	indicador a	one-hot	intervalo	seleção	sem	0,822 ± 0,005	0,607 ± 0,024	0,686 ± 0,019	0,546 ± 0,042	0,825 ± 0,013	0,621 ± 0,031	10	3,8	
98	indicador a	one-hot	intervalo	seleção	subam.	0,799 ± 0,019	0,646 ± 0,028	0,582 ± 0,031	0,728 ± 0,035	0,827 ± 0,021	0,614 ± 0,037	10	3,6	
99	indicador a	one-hot	intervalo	seleção	SMOTE	0,778 ± 0,018	0,621 ± 0,020	0,548 ± 0,030	0,719 ± 0,022	0,813 ± 0,007	0,578 ± 0,024	10	4,0	

id	ausentes	encoding	normalizacao	reducao	balanceamento	acurácia	F1	precisão	revocação	AUC	AP	atributos	tempo (s)	erro
100	indicadora	one-hot	robusta	sem	sem	0,827 ± 0,011	0,624 ± 0,019	0,695 ± 0,040	0,567 ± 0,028	0,838 ± 0,016	0,632 ± 0,029	84	0,8	
101	indicadora	one-hot	robusta	sem	subam.	0,777 ± 0,020	0,639 ± 0,026	0,541 ± 0,028	0,780 ± 0,021	0,835 ± 0,018	0,607 ± 0,031	84	0,8	
102	indicadora	one-hot	robusta	sem	SMOTE	0,747 ± 0,013	0,611 ± 0,018	0,500 ± 0,016	0,786 ± 0,028	0,821 ± 0,014	0,574 ± 0,032	84	0,9	
103	indicadora	one-hot	robusta	PCA	sem	0,818 ± 0,012	0,600 ± 0,032	0,676 ± 0,033	0,541 ± 0,048	0,830 ± 0,009	0,616 ± 0,021	22	2,8	
104	indicadora	one-hot	robusta	PCA	subam.	0,771 ± 0,018	0,630 ± 0,022	0,534 ± 0,025	0,769 ± 0,028	0,830 ± 0,019	0,604 ± 0,029	22	2,7	
105	indicadora	one-hot	robusta	PCA	SMOTE	0,761 ± 0,017	0,621 ± 0,018	0,519 ± 0,022	0,775 ± 0,014	0,818 ± 0,011	0,567 ± 0,021	22	3,0	
106	indicadora	one-hot	robusta	seleção	sem	0,825 ± 0,006	0,622 ± 0,028	0,684 ± 0,008	0,572 ± 0,051	0,822 ± 0,014	0,630 ± 0,029	10	3,9	
107	indicadora	one-hot	robusta	seleção	subam.	0,784 ± 0,021	0,631 ± 0,022	0,557 ± 0,035	0,729 ± 0,022	0,821 ± 0,015	0,607 ± 0,033	10	3,7	
108	indicadora	one-hot	robusta	seleção	SMOTE	0,778 ± 0,019	0,623 ± 0,020	0,547 ± 0,032	0,725 ± 0,030	0,813 ± 0,011	0,580 ± 0,025	10	3,9	
109	indicadora	alvo	sem	sem	sem	0,803 ± 0,009	0,518 ± 0,030	0,677 ± 0,032	0,420 ± 0,037	0,816 ± 0,015	0,570 ± 0,026	25	0,7	
110	indicadora	alvo	sem	sem	subam.	0,746 ± 0,030	0,586 ± 0,039	0,499 ± 0,039	0,711 ± 0,038	0,800 ± 0,028	0,528 ± 0,030	25	0,7	
111	indicadora	alvo	sem	sem	SMOTE	0,761 ± 0,012	0,605 ± 0,023	0,519 ± 0,016	0,728 ± 0,044	0,815 ± 0,013	0,569 ± 0,027	25	0,8	
112	indicadora	alvo	sem	PCA	sem	0,783 ± 0,016	0,471 ± 0,022	0,615 ± 0,062	0,382 ± 0,010	0,753 ± 0,014	0,509 ± 0,027	2	0,6	
113	indicadora	alvo	sem	PCA	subam.	0,670 ± 0,013	0,514 ± 0,012	0,410 ± 0,012	0,690 ± 0,028	0,732 ± 0,016	0,460 ± 0,025	2	0,6	
114	indicadora	alvo	sem	PCA	SMOTE	0,741 ± 0,015	0,550 ± 0,027	0,490 ± 0,023	0,625 ± 0,036	0,768 ± 0,012	0,531 ± 0,021	2	0,7	
115	indicadora	alvo	sem	seleção	sem	0,817 ± 0,005	0,582 ± 0,022	0,686 ± 0,016	0,506 ± 0,035	0,804 ± 0,013	0,592 ± 0,018	10	1,6	
116	indicadora	alvo	sem	seleção	subam.	0,769 ± 0,023	0,610 ± 0,033	0,534 ± 0,037	0,714 ± 0,035	0,806 ± 0,020	0,590 ± 0,019	10	1,5	
117	indicadora	alvo	sem	seleção	SMOTE	0,765 ± 0,030	0,603 ± 0,026	0,531 ± 0,045	0,702 ± 0,031	0,799 ± 0,018	0,561 ± 0,011	10	1,7	
118	indicadora	alvo	padrão	sem	sem	0,840 ± 0,005	0,656 ± 0,018	0,717 ± 0,022	0,607 ± 0,039	0,835 ± 0,011	0,647 ± 0,021	25	0,7	
119	indicadora	alvo	padrão	sem	subam.	0,805 ± 0,013	0,663 ± 0,018	0,589 ± 0,022	0,758 ± 0,023	0,846 ± 0,016	0,646 ± 0,010	25	0,9	
120	indicadora	alvo	padrão	sem	SMOTE	0,772 ± 0,014	0,623 ± 0,009	0,536 ± 0,023	0,746 ± 0,023	0,825 ± 0,009	0,602 ± 0,021	25	0,8	
121	indicadora	alvo	padrão	PCA	sem	0,838 ± 0,003	0,648 ± 0,011	0,720 ± 0,017	0,590 ± 0,026	0,837 ± 0,010	0,648 ± 0,021	14	1,1	
122	indicadora	alvo	padrão	PCA	subam.	0,798 ± 0,016	0,655 ± 0,023	0,577 ± 0,025	0,758 ± 0,024	0,847 ± 0,016	0,654 ± 0,009	14	0,9	
123	indicadora	alvo	padrão	PCA	SMOTE	0,778 ± 0,016	0,634 ± 0,021	0,545 ± 0,025	0,760 ± 0,044	0,827 ± 0,009	0,608 ± 0,027	14	1,1	
124	indicadora	alvo	padrão	seleção	sem	0,835 ± 0,008	0,648 ± 0,025	0,701 ± 0,019	0,602 ± 0,040	0,834 ± 0,009	0,651 ± 0,016	10	1,7	
125	indicadora	alvo	padrão	seleção	subam.	0,808 ± 0,015	0,662 ± 0,014	0,599 ± 0,030	0,740 ± 0,018	0,838 ± 0,008	0,631 ± 0,018	10	1,6	

id	ausentes	encoding	normalização	redução	balanceamento	acurácia	F1	precisão	revocação	AUC	AP	atributos	tempo (s)	erro
126	indicadora	alvo	padrão	seleção	SMOTE	0,781 ± 0,023	0,631 ± 0,021	0,552 ± 0,040	0,740 ± 0,015	0,821 ± 0,018	0,600 ± 0,035	10	1,8	
127	indicadora	alvo	intervalo	sem	sem	0,841 ± 0,004	0,648 ± 0,017	0,736 ± 0,008	0,580 ± 0,028	0,833 ± 0,011	0,640 ± 0,018	25	0,7	
128	indicadora	alvo	intervalo	sem	subam.	0,787 ± 0,010	0,640 ± 0,017	0,558 ± 0,014	0,751 ± 0,025	0,832 ± 0,013	0,616 ± 0,016	25	0,7	
129	indicadora	alvo	intervalo	sem	SMOTE	0,782 ± 0,014	0,631 ± 0,020	0,551 ± 0,023	0,740 ± 0,037	0,825 ± 0,013	0,605 ± 0,027	25	0,7	
130	indicadora	alvo	intervalo	PCA	sem	0,836 ± 0,008	0,638 ± 0,023	0,718 ± 0,019	0,575 ± 0,035	0,835 ± 0,013	0,634 ± 0,031	10	0,7	
131	indicadora	alvo	intervalo	PCA	subam.	0,780 ± 0,012	0,630 ± 0,016	0,548 ± 0,018	0,743 ± 0,019	0,827 ± 0,013	0,605 ± 0,017	10	0,7	
132	indicadora	alvo	intervalo	PCA	SMOTE	0,791 ± 0,019	0,640 ± 0,023	0,568 ± 0,032	0,734 ± 0,024	0,828 ± 0,018	0,608 ± 0,036	10	0,8	
133	indicadora	alvo	intervalo	seleção	sem	0,838 ± 0,001	0,648 ± 0,014	0,719 ± 0,019	0,592 ± 0,033	0,839 ± 0,008	0,664 ± 0,025	10	1,7	
134	indicadora	alvo	intervalo	seleção	subam.	0,813 ± 0,009	0,663 ± 0,013	0,609 ± 0,018	0,729 ± 0,022	0,843 ± 0,007	0,644 ± 0,015	10	1,6	
135	indicadora	alvo	intervalo	seleção	SMOTE	0,798 ± 0,015	0,653 ± 0,015	0,578 ± 0,026	0,751 ± 0,022	0,831 ± 0,012	0,618 ± 0,031	10	1,7	
136	indicadora	alvo	robusta	sem	sem	0,839 ± 0,006	0,650 ± 0,023	0,721 ± 0,019	0,593 ± 0,044	0,837 ± 0,017	0,639 ± 0,025	25	0,7	
137	indicadora	alvo	robusta	sem	subam.	0,799 ± 0,007	0,657 ± 0,011	0,577 ± 0,012	0,762 ± 0,021	0,841 ± 0,015	0,625 ± 0,021	25	0,7	
138	indicadora	alvo	robusta	sem	SMOTE	0,770 ± 0,015	0,628 ± 0,016	0,531 ± 0,023	0,769 ± 0,021	0,821 ± 0,012	0,583 ± 0,025	25	0,8	
139	indicadora	alvo	robusta	PCA	sem	0,832 ± 0,009	0,644 ± 0,019	0,695 ± 0,027	0,601 ± 0,027	0,833 ± 0,013	0,630 ± 0,023	11	0,9	
140	indicadora	alvo	robusta	PCA	subam.	0,796 ± 0,005	0,649 ± 0,005	0,575 ± 0,012	0,746 ± 0,023	0,838 ± 0,017	0,622 ± 0,024	11	0,9	
141	indicadora	alvo	robusta	PCA	SMOTE	0,770 ± 0,018	0,628 ± 0,019	0,532 ± 0,025	0,768 ± 0,033	0,823 ± 0,012	0,590 ± 0,013	11	1,0	
142	indicadora	alvo	robusta	seleção	sem	0,830 ± 0,011	0,640 ± 0,023	0,690 ± 0,036	0,598 ± 0,032	0,829 ± 0,009	0,637 ± 0,028	10	1,8	
143	indicadora	alvo	robusta	seleção	subam.	0,793 ± 0,020	0,645 ± 0,020	0,571 ± 0,034	0,743 ± 0,009	0,831 ± 0,007	0,618 ± 0,026	10	1,7	
144	indicadora	alvo	robusta	seleção	SMOTE	0,779 ± 0,019	0,630 ± 0,020	0,548 ± 0,030	0,743 ± 0,016	0,818 ± 0,015	0,588 ± 0,029	10	1,8	

Tabela A.1. Resultado das 144 combinações nos cinco folds.

B. Ambiente de execução

item	valor
Python	3.13.16
scikit-learn	1.9.1
imbalanced-learn	0.14.2
pandas	3.0.5
numpy	2.5.3
sistema	Linux 6.18

item	valor
semente	42
validação	StratifiedKFold de 5 folds, embaralhado, semente 42
vizinhos do kNN	7

Tabela B.1. Ambiente de execução.

Gravado pela própria execução em reports/e2/ambiente.json. Executar a grade duas vezes neste mesmo ambiente produz as mesmas métricas em todos os folds, o que confirma que nenhum transformador ficou sem semente.

Uma observação de reprodutibilidade que vale registrar. A grade também foi executada num segundo ambiente, Windows com Python 3.12 e scikit-learn 1.9.0. As conclusões não mudam: a melhor e a pior combinação são as mesmas, o baseline fica na mesma faixa e todas as contagens pareadas da seção 5.2 mudam, no máximo, uma unidade. As métricas de corte, porém, diferem na terceira decimal, com diferença máxima de 0,015 em precisão. A causa é a ordem de soma em ponto flutuante no cálculo das distâncias, que desempata de forma diferente quando dois vizinhos estão à mesma distância do filme avaliado. Os números deste relatório são todos do ambiente da tabela acima, que é o da execução gravada no repositório.

C. Partição em folds

O fold de cada um dos 2.590 filmes está em reports/e2/folds.csv, gerado uma única vez por python src/e2/base.py. As 144 combinações e as três checagens de robustez recebem essa lista de índices e não reconstroem a partição, de modo que qualquer diferença entre duas linhas da tabela vem do pré-processamento e não da divisão dos dados.

D. Arquivos gerados pela execução

arquivo	conteúdo
resultados.csv	uma linha por combinação, com média e desvio de cada métrica
resultados_por_fold.csv	720 linhas, uma por combinação e fold, base da leitura pareada
folds.csv	o fold de cada filme
ambiente.json	versões, semente, ordem das etapas e data da execução
anexo_144.md e anexo_144.csv	a tabela deste anexo
analise_ranking.csv	as 144 ordenadas, com as colunas de empate
analise_efeitos.csv	as duas leituras do efeito de cada etapa
analise_interacoes.csv	as tabelas de interação da seção 5.3
analise_custo_por_opcao.csv e analise_custo_mais_caras.csv	a seção 5.4
robustez_temporal.csv, robustez_limiar.csv, robustez_limiar_spearman.csv, robustez_genero.csv	as três checagens da seção 6

Tabela D.1. Arquivos gerados pela execução.

E. Onde está cada coisa no código

conteúdo	caminho
base, alvo e folds da E2	src/e2/base.py

conteúdo

espaço das 144 combinações e montagem do pipeline
uma etapa por módulo
métricas
execução da grade
leitura dos resultados e regra de empate
robustez
tabela deste anexo
testes

Tabela E.1. Onde está cada coisa no código.

caminho

src/e2/espaco.py
src/e2/etapas/
src/e2/metricas.py
src/executar_e2.py
src/e2/analise.py
src/e2/robustez.py
src/e2/anexo.py
tests/test_e1.py e tests/test_e2.py